

基于 CWT 和 CNN-BiLSTM 的散绕同步电机定子 绕组短路故障检测方法

于跃强¹, 陈宇², 赵仲勇^{1,3}, 宫小宇⁴, 唐超¹

(1. 西南大学工程技术学院, 重庆 400716; 2. 华中科技大学电气与电子工程学院强电磁技术全国重点实验室, 武汉 430074; 3. 西南大学宜宾研究院, 宜宾 644000; 4. 国网重庆市电力公司北碚供电分公司, 重庆 400014)

摘要: 近年来, 基于脉冲频率响应法(impulse frequency response analysis, IFRA)的神经网络模型已被证实能够有效检测定子绕组故障。然而, 这些模型普遍具有鲁棒性不强、抗噪能力差等特点, 究其原因是大多数的模型采用简单的神经网络架构且常规的 IFRA 普遍采用快速傅里叶变换(fast Fourier transform, FFT)对暂态信号进行时频变换, 而 FFT 并不适合处理暂态突变的非平稳信号。文中以散绕结构的同步电机定子绕组为检测对象, 采用连续小波变换(continual wavelet transform, CWT)代替 FFT 处理 IFRA 的暂态信号, 并基于一维卷积神经网络(convolutional neural networks, CNN)和双向长短时记忆网络(bi-directional long short-term memory, BiLSTM)构建 CNN-BiLSTM 模型对采用 CWT 变换之后的信号进行故障检测。实验结果表明: 采用 CWT 处理后的频域序列作为该模型的输入, 相较于其它结构单一的模型, 其平均准确率最优且高达 99.01%。噪声对比实验表明: 采用 CWT 变换后的数据能使故障诊断模型的鲁棒性及泛化性更强。

关键词: 同步电机; 定子绕组; 脉冲频率响应法; 小波变换; CNN-BiLSTM

Detection Method of Stator Winding Short Circuit Fault of Synchronous Motor Based on CWT and CNN-BiLSTM

YU Yueqiang¹, CHEN Yu², ZHAO Zhongyong^{1,3}, GONG Xiaoyu⁴, TANG Chao¹

(1. College of Engineering and Technology, Southwest University, Chongqing 400716, China; 2. State Key Laboratory of Advanced Electromagnetic Technology, School of Electrical and Electronic Engineering, Huazhong University of Science and Technology, Wuhan 430074, China; 3. Yibin Academy of Southwest University, Yibin 644000, China; 4. Beibei Power Supply Branch of State Grid Chongqing Electric Power Company, Chongqing 400014, China)

Abstract: In recent years, neural network models based on impulse frequency response analysis (IFRA) have been proven effective in detecting stator winding faults. However, these models are generally characterized by weak robustness and poor noise resistance. The reason is that most of the models adopt simple neural network architecture and conventional IFRA generally use fast Fourier transform (FFT) to perform time-frequency transformation on transient signals, while FFT is not suitable for processing transient abrupt non-stationary signals. In this paper, the stator winding of a loose wound synchronous machine is taken as the detection object and continuous wavelet transform (CWT) instead of FFT is used to process the transient signal of IFRA, and based on one-dimensional convolutional neural networks (CNN) and bi-directional long short term memory (BiLSTM) networks, a CNN-BiLSTM model is constructed to detect the fault of the data transformed by CWT. The experimental results show that, compared with other models with the transformed single, the CNN-BiLSTM model with CWT processed frequency domain sequence as input has the best average accuracy of 99.01%. The noise contrast experiment shows that data transformed by CWT can enable the fault diagnosis model to be more robust and generalized.

Key words: synchronous machine; stator winding; impulse frequency response analysis; continual wavelet transform; CNN-BiLSTM

基金资助项目: 四川省科技计划(2023NSFSC0829); 中央高校基本科研业务费项目(SWU-KT22027); 国家自然科学基金(51807166)。
Project supported by Sichuan Science and Technology Program (2023NSFSC0829), Fundamental Research Funds for the Central Universities(SWU-KT22027), National Natural Science Foundation of China(51807166).

0 引言

同步电机被广泛应用在电力系统、航天领域、工业生产等各个方面, 其安全运行关乎国计民生。定子绕组是同步电机重要组成部分, 但由于其长期运行会导致定子绕组的绝缘层逐渐老化。同步电机的可靠运行关系着电力系统的稳定性以及工业生产的可靠性, 而定子绕组匝间和接地短路故障是同步电机中常见的故障。定子故障源于绕组局部放电导致绕组的绝缘材料老化^[1-3], 绝缘老化具有累计效应且其会持续降低绕组的绝缘性能从而引起绝缘击穿, 而绝缘击穿会引发瞬时的大电流从而引起绕组短路故障, 短路故障包括匝间短路(inter turn short circuit, ITSC)故障和接地短路(ground short circuit, GSC)故障^[4]。由于故障而造成的同步电机停运会对社会造成巨大的经济损失, 故及时且准确地检测定子绕组短路故障的发生, 对于维持电力系统稳定运行以及保证相关产业的经济效益具有重要意义。

目前, 同步电机定子绕组检测可分为状态监测和故障诊断。相比于故障诊断, 状态监测可实时监测定子绕组的状态变化, 但是大多数状态监测法(如探测线圈法^[5]、电流谐波特征法^[6])需要额外安装高精度传感器去采集特征数据, 对于一些已投入运行的同步电机, 其内部结构已固定, 安装额外的传感器较为困难且成本较高。

频率响应分析(frequency response analysis, FRA)是一种快速、简单且无损的故障检测方法, 该方法具有较高的稳定性和灵敏性而被广泛应用于绕组故障检测^[7]。例如在机组进行定期维护或进行抽检时, 使用 FRA 可检测绕组的质量, 甚至判断绕组是否发生故障。FRA 因注入不同的信号而分为扫频分析法(sweep frequency response analysis, SFRA)和脉冲频率响应分析法(impulse frequency response analysis, IFRA)^[8]。由于 SFRA 是直接注入不同频率的正弦信号, 不需要经过时频转换的步骤, 所以该方法具有较强的鲁棒性且不易受到白噪声影响。文献[9]详细地介绍了近几年 FRA 法应用在不同类型及不同功率大小电机绕组检测的适用性。例如, 文献[10]表明 FRA 分析能够检测功率为 660 kW 的风力发电机定子绕组故障。文献[11]表明 FRA 法能够表征额定功率为 53、65、120 MVA 的水轮发电机定子绕组的状态变化。此外, 文献[12]使用 SFRA 诊断不同类型和不同程度的定子绕组故障, 并探究了转子的位

置对定子绕组的 FRA 曲线影响。文献[13]研究表明, SFRA 能够准确反映定子绕组短路故障的程度为 1%。但 SFRA 仪器成本高, 检测时间较长, 而 IFRA 相比于 SFRA, 设备成本低, 检测时间快, 使得 IFRA 成为 SFRA 一种替代方案。目前, 大多数 IFRA 是使用脉冲源在定子绕组首端产生暂态信号并从绕组末端获取响应信号, 之后使用快速傅里叶变换(fast Fourier transform, FFT)来得到频率响应曲线。然而, 实际上, FFT 只适合处理平稳信号, 处理暂态信号容易造成频谱泄漏和栅栏现象等缺陷^[14]。此外, FFT 处理含噪的暂态信号可能会导致频率响应曲线的一些关键信息被噪声湮没, 从而造成专业人员对绕组状态的误判断。而连续小波变换(continuous wavelet transform, CWT)通过伸缩平移运算对信号逐步进行多尺度细化, 最终达到高频处和低频处的频率细分, 具有解决上述问题的潜力。

另一方面, 无论是 SFRA 和 IFRA, 传统的故障诊断方法仍然是基于数理统计指标去衡量频率响应曲线的变化趋势, 从而诊断绕组的故障程度、类型和位置, 因而基于 FRA 的绕组故障诊断仍需要复杂的计算及有经验的技术人员。此外, 一些研究采用统计指标去建立绕组故障的阈值^[15], 该阈值的建立具有主观性, 对于不同的同步电机绕组可能不适用。机器学习为上述问题提供一种有效的解决方案, 有几种典型的模型已被成功应用于电机故障诊断, 包括卷积神经网络(convolutional neural networks, CNN)^[16]、深度置信网络(deep belief network, DBN)^[17]、支持向量机(support vector machine, SVM)^[18]。例如, 文献[19]使用自检验长短期记忆网络(self-checking long short-term memory, Sc-LSTM)模型对机组的轴承进行状态评价。文献[20]基于生成式对抗网络(conditional generative adversarial network, CGAN)和 CNN 对同步电机励磁绕组的 ITSC 故障进行分类。文献[21]利用电机的多源信号作为 DBN 网络的输入确定励磁绕组的故障阈值。文献[22]基于孤立森林和 IFRA 对同步电机绕组进行异常检测, 但该模型并没有对故障类型进行分类。文献[23]基于遗传算法优化的神经网络模型对电机绕组进行故障诊断, 该方法需要依靠于各种数理统计指标与故障状态之间的映射关系。文献[24]提出一种基于骨干微粒群算法对故障电机的定子电流进行滤波, 并采用 SVM 模型对电流的谐波特征信号进行故障分类。上述方法的模型结构较为简单, 无

法做到简单性与有效性之间的平衡；大部分模型无法有效处理带有噪声的输入且鲁棒性较差；大部分方法都是依据于先验的数理统计指标且无法做到自动提取序列维度的特征信息。为克服上述缺点，本文提出一种基于 CNN 和双向长短时记忆神经网络 (bi-directional long short term memory, BiLSTM) 的同步电机定子绕组短路故障诊断方法。

本文的主要贡献在于：(1)采用 CWT 代替 FFT 处理暂态信号，提高绕组 FRA 曲线计算的准确性，时频转化过程以及故障诊断网络模型的抗噪性得到显著提升。(2)提出一种基于 CNN-BiLSTM 的绕组故障诊断模型，无需相关先验知识且端到端地挖掘数据特征以提高模型的精度；在自动化识别绕组短路故障类型及程度的前提下，具有较高的准确性。

本文首先在第 1 章简要地介绍了 IFRA、CWT、CNN-BiLSTM 的原理；第 2 章是 CWT 方法的电路仿真实验验证；第 3 章对一台 5 kW 散绕结构的同步电机进行数据集采集及数据集的特征可视化；第 4 章是使用 CNN-BiLSTM 对定子绕组短路故障进行分类诊断；第 5 章为本文的结论。

1 IFRA 法、CWT 及 CNN-BiLSTM 深度学习模型原理

1.1 IFRA 原理

定子绕组在高频信号作用下，可等效为由电阻、电感、电容级联的宽频等效电路模型，电路模型如图 1 所示^[25]。IFRA 是向绕组注入单个脉冲信号作为激励信号，将激励信号和绕组末端的响应信号通过 FFT 进行时频变换，获得绕组的激励频谱分量 $U_{in}(\omega)$ 和响应频谱分量 $I_{out}(\omega)$ ，并求解其传递函数 $H(\omega)$ ，其见式(1)—(3)。 $H(\omega)$ 表示绕组的频率响应曲线，其单位表示为 dB。当绕组发生故障时，势必引发等效电路模型结构及参数的改变，导致 $H(\omega)$ 发生变化，通过分析频率响应曲线特征点的变化来诊断绕组的故障类型及故障程度。

图 1 中： U_{in} 和 I_{out} 为注入绕组的激励电压信号及响应电流信号， R_{si} 和 L_i 为第 i 个基本单元的电阻和自感， C_{2i} 和 K_i 为第 i 个基本单元的对地电容和串联电容， M_{ni} 为第 i 个和第 n 个基本单元间的互感。

$$U_{in}(\omega) = \sum_{n=0}^{N-1} U_{in}(n) e^{-j\frac{2\pi}{N}\omega n} \quad (1)$$

$$I_{out}(\omega) = \sum_{n=0}^{N-1} I_{out}(n) e^{-j\frac{2\pi}{N}\omega n} \quad (2)$$

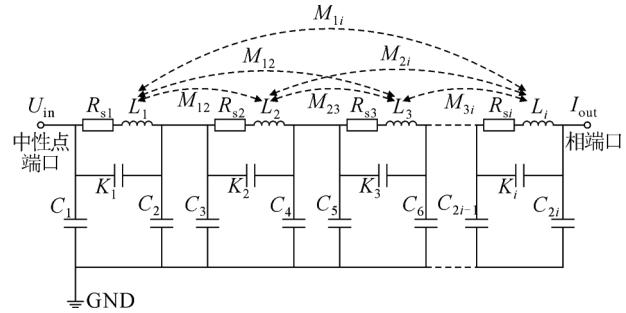


图 1 定子绕组宽频等效电路模型^[25]

Fig.1 Broadband equivalent circuit model of the stator winding^[25]

$$H(\omega) = 20 \lg \frac{|I_{out}(\omega)|}{|U_{in}(\omega)|} \quad (3)$$

式中： N 是采样信号的长度； $\omega = 0, 1, 2, \dots, N-1$ ； $U_{in}(n)$ 和 $I_{out}(n)$ 是激励和响应信号的时域离散序列； $U_{in}(\omega)$ 和 $I_{out}(\omega)$ 是激励和响应信号的频谱分量。

1.2 CWT 原理

由于 CWT 有着良好的时频局部化特性，其基是自然收敛的，更适合处理非平稳信号，对于任意一个信号 $f(t)$ ，其连续小波变换如下：

$$W_{T_f}(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} f(t) \varphi\left(\frac{t-b}{a}\right) dt \quad (4)$$

式中： b 为平移因子，决定时频窗在时域的位置； a 为尺度因子，决定时频窗的大小及其在频域的位置； $\varphi(t)$ 为平移及尺度变化后的小波基函数。

要能准确地将脉冲信号分解为不同的频谱分量，需选择合适的母小波及其参数。根据文献[9-12, 26-28]研究结果显示，不同功率的电机定子绕组的频率特征点集中在 1 MHz 以下，所以需得到宽频的 IFRA 特征曲线(1 kHz~1 MHz)。由于复 Morlet 小波中心频率较高，易于提取频率范围较宽的暂态信号，所以本文选择复 Morlet 小波作为母小波，其时域表达见式(5)， F_b 为带宽， F_c 为中心频率。

$$\varphi(t) = \frac{1}{\sqrt{F_b \pi}} e^{\frac{-t^2}{F_b}} e^{2i\pi F_c t} \quad (5)$$

研究人员通常使用“试错法”选择合适的小波参数^[29]，由于 F_c 是在各个尺度下沿频率轴移动，因而参数 F_c 对结果的分析影响是小于 F_b 。实际验证表明， F_c 应取较大的值，使分析的频带在相对低频的范围。此外， F_b 决定了高斯窗标准方差的特性， F_b 越小，高斯窗越窄。图 2 为同一 F_c 下，不同 F_b 的复 Morlet 小波时域及频谱图。从图 2 所知， F_b 越大，带宽越小，直至一个脉冲，所以为了获得更精确的频率，需采用较大的 F_b 。

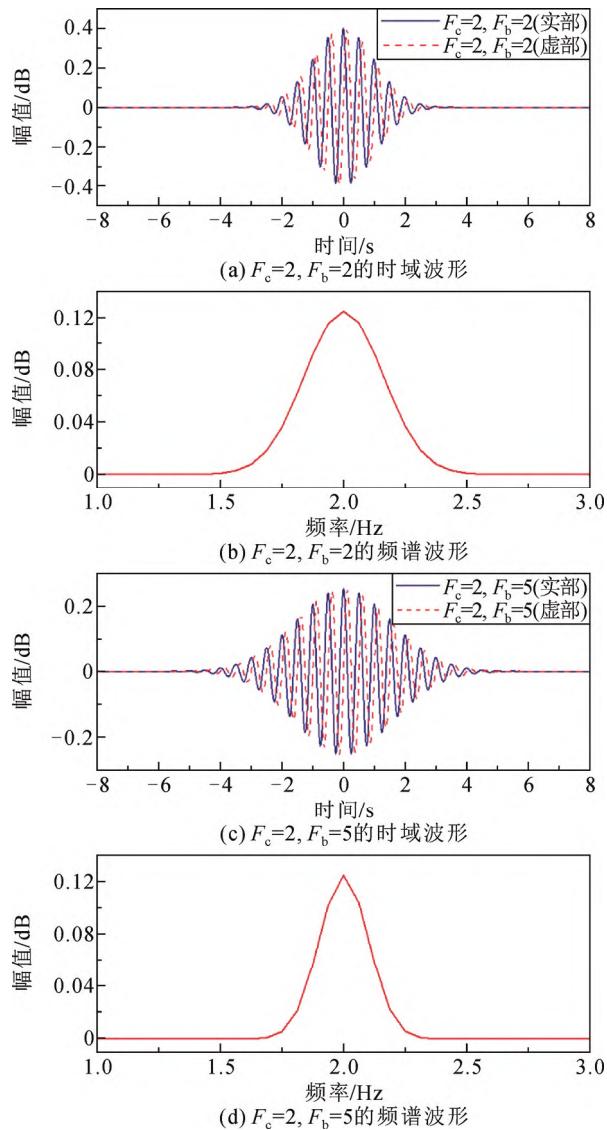


图 2 带宽参数对复 Morlet 小波波形及频谱影响

Fig.2 Effect of bandwidth parameters on waveform and spectrum of complex morlet wavelet

图 3 以注入绕组的激励信号和采集的响应信号为例, 展示 CWT 的转换过程, 具体步骤如下:

- 1) 采集 IFRA 输入的激励信号 $U_{in}(t)$ 和响应信号 $I_{out}(t)$, 并筛选合适的母小波及其参数。
- 2) 根据式(4)求出连续小波变换系数 $W_{T,in}(\omega, b)$ 和 $W_{T,out}(\omega, b)$ 。
- 3) 将小波系数取模后对时间域积分, 得到其幅值的频域分布后, 再根据 IFRA 定义, 获得其 IFRA 特征曲线, 其特征曲线 $H_{CWT}(\omega)$ 见式(6)^[30]。

$$H_{CWT}(\omega) = \frac{\int_{-\infty}^{+\infty} |W_{T,in}(\omega, b)| dt}{\int_{-\infty}^{+\infty} |W_{T,out}(\omega, b)| dt} \quad (6)$$

$$H_{dB}(\omega) = 20 \lg(H_{CWT}(\omega)) \quad (7)$$

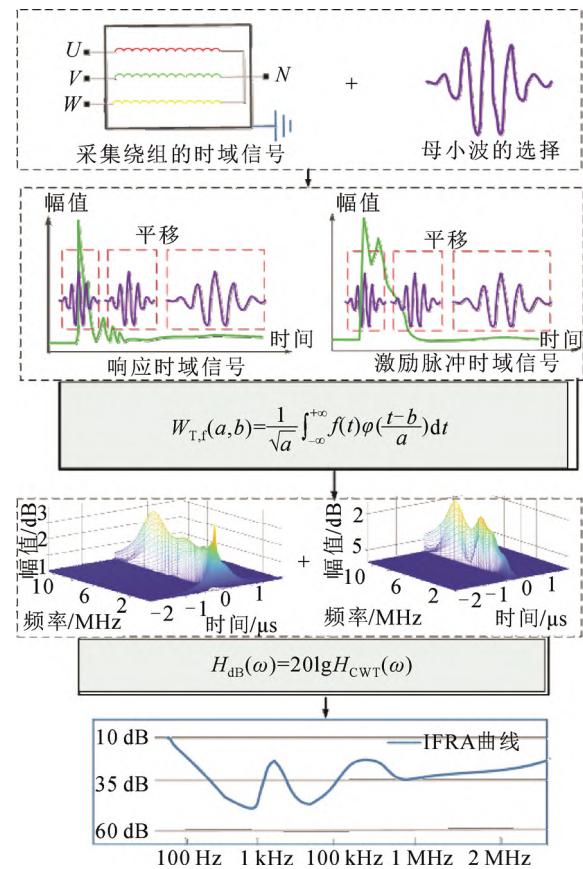


图 3 基于 CWT 的 IFRA 转换流程图

Fig.3 IFRA conversion process based on CWT

式中: $H_{dB}(\omega)$ 为频率响应曲线的增益, dB。

1.3 CNN-BiLSTM 网络模型原理

使用一维 CNN 能减少输入序列的维度并且提高模型训练速度, 使网络模型能够轻量化。此外, 一维 CNN 里面卷积核具有类似数字滤波器的降噪效果, 能提高模型的抗噪能力。

LSTM 是一种特殊的循环神经网络(recurrent neural network, RNN)结构, 相比简单的 RNN, LSTM 能够在更长的序列中有更好的表现。为增加历史序列对当前序列的影响, 研究人员提出了 BiLSTM, 内部结构如图 4 所示。图中, σ 为 sigmoid 激活函数; f_t 、 i_t 、 \hat{C}_t 、 O_t 分别为 t 时刻的遗忘门值、输入门值、候选状态及输出门值。与 LSTM 相比, BiLSTM 增加了一条逆向读取序列信息的路径, 可同时从正反两个方向上提取数据特征, 从而使得网络效果更佳。

本文首先使用一维 CNN 进行数据聚合并使输入的序列降维, 之后利用 BiLSTM 提取序列维度上的特征信息, 并通过全连接层进行故障分类。基于上述分析, 本文设计了一种基于 CNN-BiLSTM 网络的故障诊断模型, 该模型网络由 5 层组成, 其网

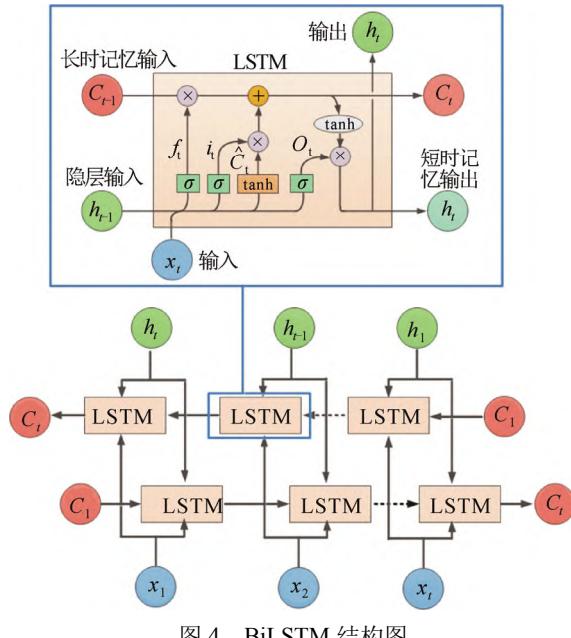


图 4 BiLSTM 结构图

Fig.4 BiLSTM structure diagram

络结构与具体参数如图 5 所示。此模型代替了指标选择与专家判断过程。

2 基于 CWT 计算 IFRA 曲线的仿真实验验证

为了探究 CWT 处理脉冲激励信号及响应信号的可行性, 基于课题组前期工作^[31], 建立一个同步电机定子绕组的宽频等值电路模型, 该模型由电阻、电容、电感构成的 π 型电路级联组成, 电机的参数见表 1, 其电路模型见图 6 所示, 模型的参数见表 2。尽管该电机为一台散绕结构的同步发电机, 其绝缘系统及绕线方式与大型同步发电机有所区别, 但定子绕组在高频信号下都可以建模为由电容、电感和电阻网络的等效电路, 其频率响应是独一无二的。因此, 绕组的任何故障都会导致等效电路的变化, 故其频率响应曲线也会发生变化。此外, 尽管不同功率大小的电机定子绕组有不同的电感及分布电容, 而绕组的电感及分布电容参数影响频率响应曲线的谐振点。但由于大多数不同功率^[10-11](包括 37 kVA、660 kVA、53 MVA、65 MVA、120 MVA)的同步发电机定子绕组的频率特征分析点集中在 1 MHz 以下, 证明该方法能够适用于诊断不同功率大小的同步发电机定子绕组绝缘及匝间故障。因此本文采用散绕结构的 5 kW 同步发电机去验证本文所提出方法的有效性。

本文使用 Simulink 仿真软件对该电路模型进行暂态仿真, 并对仿真后的数据进行处理。首先, 将

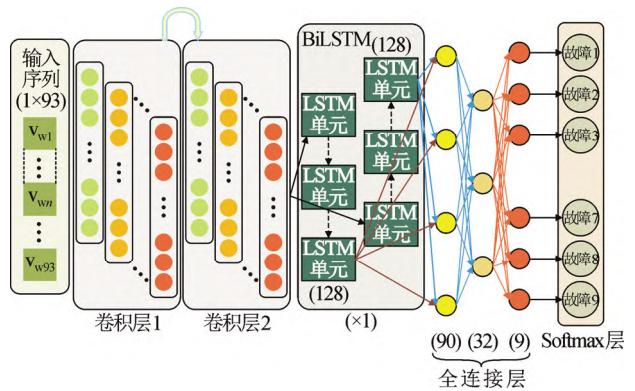


图 5 基于 CNN-BiLSTM 的定子绕组短路故障诊断深度学习网络架构

Fig.5 Fault detection network structure for stator windings based on CNN-BiLSTM

表 1 同步电机铭牌值

Table 1 Nameplate values of synchronous machine

参数	额定功率/kW	额定电压/V	极对数	频率/Hz	定子槽数	额定转速/(r·min⁻¹)
数值	5	380	1	50	36	1500

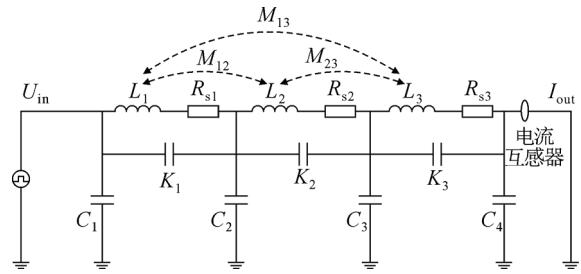
图 6 模拟定子绕组的宽频等效电路模型^[31]

Fig.6 Simulates the broadband equivalent circuit model of the stator winding^[31]

表 2 模拟定子绕组等效参数^[31]Table 2 Equivalent parameters of simulated stator winding^[31]

参数	数值	参数	数值	参数	数值
R_{s1}	4.11252 mΩ	C_1	6.30636 nF	L_3	30.272 μH
R_{s2}	6.27517 μΩ	C_2	3.715×10^{-6} nF	K_1	6.13099 nF
R_{s3}	5.35873 Ω	C_3	9.56255 nF	K_2	5.18056 nF
M_{12}	584.391 μH	C_4	0.51541 nF	K_3	12.7793 nF
M_{13}	23.9343 μH	L_1	59.4174 μH		
M_{23}	26.4791 μH	L_2	1.89469 mH		

频率 1 kHz、脉宽 300 ns、上升沿 40 ns、下降沿 40 ns 的脉冲信号注入等效电路模型, 并导出采样后的仿真数据。将仿真数据分别经过 FFT 和 CWT 变换。此外, 为验证 CWT 的有效性, 将 1 Hz—1 MHz 的正弦信号注入等效电路模型得到 SFRA 的频率响应

曲线, 并对 3 种方法的结果进行对比, 数据处理结果如图 7 所示。

从图 7 可知, 时域信号经过 FFT 和 CWT 处理后, IFRA 曲线都较为接近 SFRA 曲线。此外, 经过 FFT 处理的数据在 A 点处的增益远远小于 SFRA, 而经过 CWT 处理后的频率响应曲线在谐振峰的值较为接近原始 SFRA 曲线的谐振峰, 说明本文提出使用 CWT 处理暂态信号获取频率响应曲线相比于 FFT 具有一定的优越性。此外, 在实际工程运用中, 采集的暂态信号由于环境的影响夹杂无法避免的噪声。为研究 FFT 和 CWT 处理实际绕组的暂态信号的性能表现, 将仿真后的数据均匀的添加不同程度的高斯白噪声, 以模拟实际暂态信号的信噪比(signal-to-noise ratio, SNR)。为了直观的显示 FFT 和 CWT 处理不同程度的暂态信号 SNR 差异, 从每种不同程度的 SNR 频率响应曲线纵轴上减去一个常数值, 以分离频率响应曲线。图 8 为添加的噪声数据通过 FFT 和 CWT 处理的对比图。

图 8 可以看出, 经过 FFT 处理后的 SNR-20 和 SNR-10 频率响应曲线存在大量冗余谐振点, 并随着信噪比的减小, 谐振点不断增加, 这将严重影响绕组故障的判断。而采用 CWT 处理得到的频率响应曲线较为平滑, 同时其主要谐振频率点保持不变, 表明 CWT 算法相比于 FFT 在实际工程运用中更适合处理暂态信号。

3 基于 IFRA 的定子绕组故障模拟实验

3.1 定子绕组故障数据集

为提供深度学习的数据基础, 在上述的三相同步电机进行 IFRA 实验, 其铭牌参数见表 1。图 9 为 IFRA 测量的接线图及定子绕组短路故障设置, 其中本文设置的 GSC 故障是将 U 相的 1 号抽头分别直接接地和串联 10、20、40 Ω 后接地, ITSC 故障是将 U 相的 1 号抽头分别和 2、3 号抽头连接, 并分别串联 10 Ω 的电阻模拟不同程度的故障。脉冲信号参数设置如下: 频率为 1 kHz、脉宽为 300 ns、幅值为 500 V, 采样频率设置为 25 MHz。激励信号采用泰克 P5100A 宽频带电压探头(带宽: 500 MHz)测量, 响应信号采用 Pearson 宽频电流传感器(型号: 150, 带宽: 40 Hz~20 MHz, 每安培输出电压: 0.5 V)测量。另外, 每一个样本均测量 64 次以减小测量误差和噪声对频率响应曲线的影响。

该数据集包含 200 组健康绕组数据及 1608 组

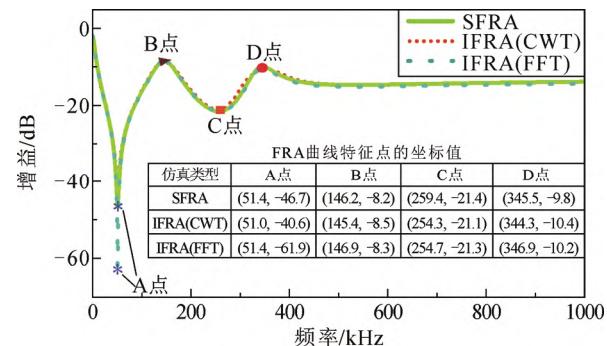


图 7 绕组宽频等值电路的 SFRA 及 IFRA 仿真结果对比

Fig.7 Comparison of SFRA and IFRA simulation results for winding broadband equivalent circuits

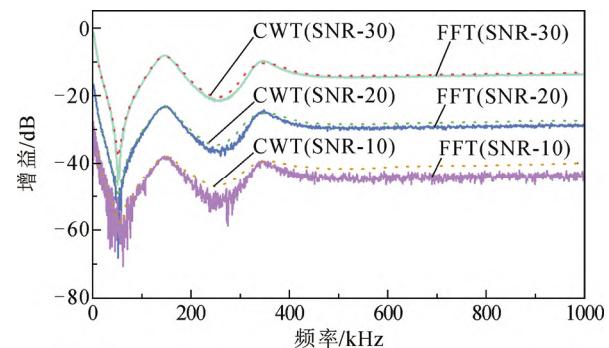


图 8 FFT 和 CWT 处理不同信噪比值的暂态信号数据

Fig.8 FFT and CWT process transient signals with different SNR

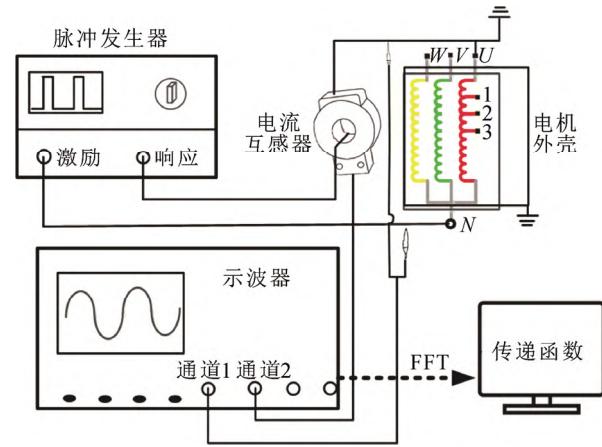


图 9 IFRA 测量接线示意图

Fig.9 Wiring diagram of IFRA measurement

故障数据, 故障数据包含 2 种不同类型的故障, 即 ITSC 和 GSC, 每种不同类型的故障包含 4 种不同程度的故障。其中随机选取 1605 组作为训练集, 203 组作为测试集。本文为了简化流程, 将每一种数据类型用编号 0、1、…、8 替代, GSC(1 号-0 Ω) 代表 U 相绕组的第一个端子与电阻串联并接地以模拟不同程度的 GSC 故障, ITSC(1 号-2 号-0 Ω) 代表

U相绕组的第1个端子与第2个端子之间连接电阻以模拟不同程度的ITSC故障，其他可以此类推。绕组故障的时域波形及频域如图10所示，数据集信息见表3。

从图10可以看出，绕组的ITSC故障和GSC故障都会导致激励电压及响应电流幅值降低。激励电压信号与响应电流信号的时域波形在1~5μs处的幅值随着不同程度的绕组故障发生一定程度的减小。在4μs时刻，电压振荡幅值随故障程度的增加从100V减小到0V。从IFRA波形图中可进一步地看出，不同的故障类型及故障程度在50~500kHz频段内变化较为明显，具体表现为：IFRA曲线整体向高频方向偏移，且增益随着不同故障而呈现不同程度的增加，这是因为匝间故障和接地故障导致绕组的高频阻抗特性发生变化。此外，相比于FFT，采用CWT处理得到的IFRA曲线更为平滑，在实际工程运用中更有辨识度。

3.2 定子绕组故障数据集的可视化特征

将采集的测试集数据分别通过FFT与CWT变换到频域数据集，将频域数据集序列数据作为输入，通过T-SNE(t-distributed stochastic neighbor embedding)降维并进行特征图可视化。T-SNE可以将高维数据内部的特征放大，使得相似的数据在低维中能更加接近，不相似的数据在低维中距离更远，其结果如图11所示。其中每一个点代表一个样本，不同颜色代表不同类型或不同程度的故障。

在图11中，正如第3章仿真测试结果一样，相比于FFT，CWT处理后的频域数据更有利于故障的辨识。这是因为实际暂态信号经过FFT处理得到的频率响应曲线含有大量的伪谐振点，使得绕组故障类型及故障程度难以区分。而CWT本质上是一组

表3 同步电机在各种故障状态下的IFRA数据集

Table 3 IFRA data set of synchronous machine under various fault conditions

类型	标签	训练集	测试集
GSC(1号-0Ω)	0	168	34
GSC(1号-10Ω)	1	187	15
GSC(1号-20Ω)	2	184	17
GSC(1号-40Ω)	3	176	25
ITSC(1号-2号-0Ω)	4	185	16
ITSC(1号-2号-10Ω)	5	178	23
ITSC(1号-3号-0Ω)	6	176	24
ITSC(1号-3号-10Ω)	7	168	32
正常	8	183	17

可控制通带范围的多尺度滤波器，所以经过CWT处理后的频率响应曲线更平滑，导致其可视化特征会比FFT更有分辨度。

4 采用CNN-BiLSTM进行故障诊断的结果分析

为了研究CNN-BiLSTM网络结构的预测性能，模型训练时的超参数为：mini-batch为32，epoch

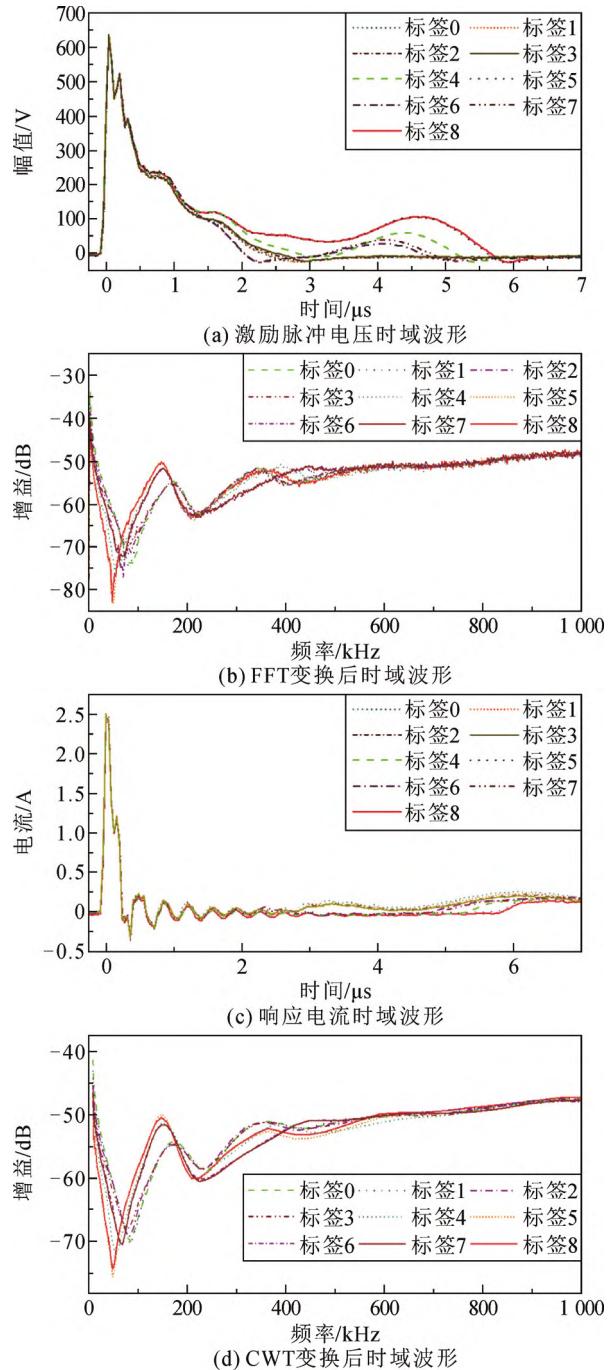


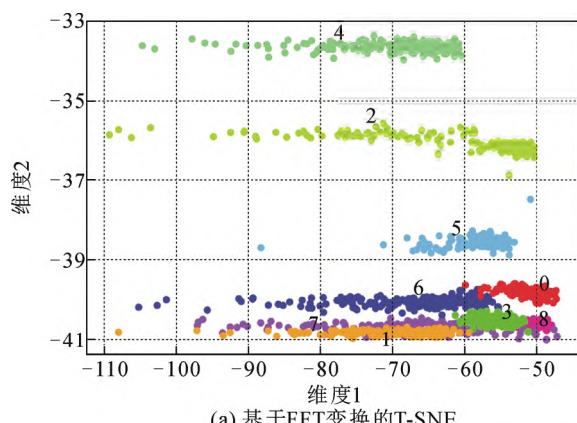
图10 IFRA测量时域及频域波形图

Fig.10 IFRA measurement time domain waveform and frequency domain waveform

为 3000, 优化器 Adam, 损失函数交叉熵。表 4 为设置不同学习率而得到相应准确率的结果。

从表 4 可以看出, 随着学习率的增强, 模型的训练精度增加, 因此, 本文设置学习率为 0.001, 而图 12 为 CNN-BiLSTM 模型在训练过程中的损失函数曲线图。

模型的训练是通过寻找梯度来最小化损失函数, 损失函数的大小能够反映目前模型的分类能力与训练情况。从图 12 中的损失函数曲线的总体趋势来看: 训练早期收敛速度较快, 训练中后期网络的收敛速度趋于稳定, 训练将要结束时收敛于最优解附近, 损失函数曲线不再发生太大变化, 因此稳定地收敛到一个较小的常数。在图 12 中, 损失函数曲线的另一个特征是振荡收敛到最小值。曲线振荡的原因是训练集被分成几个小批量学习, 每次网络更新的权重参数基于每个小批量来计算梯度, 而不是



(a) 基于FFT变换的T-SNE

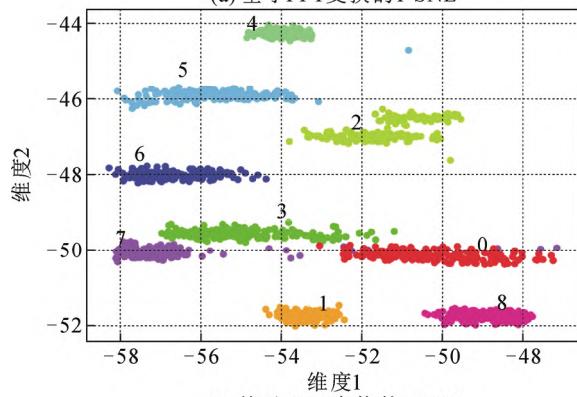


图 11 定子绕组故障的 T-SNE 图

Fig.11 T-SNE diagram of stator winding fault

表 4 不同学习率模型的性能统计表

Table 4 Performance statistics of other models

学习率	0.0001	0.0003	0.0005	0.0007	0.001
准确率/%	96.05	98.52	98.52	98.52	99.01

整个训练集的损失函数梯度, 因此损失函数曲线会振荡。

图 13 为 CNN-BiLSTM 在测试集上的混淆矩阵, 图下方标识标签为模型预测标签, 即模型的目标, 左侧标识标签为真实标签。以模型的输出与目标作为索引, 在索引对应的方框内显示有相应的样本个数。此外, 如果模型分类正确, 则方框显示为深色, 如果分类错误, 则方框显示为浅色。

从图 13 可以看出, 该模型的检测精度为 99.01%, 除故障 2 检测率小于 90%, 其他故障类型的分类精度为 100%。因此, CNN-BiLSTM 可以有效诊断大部分故障, 只有少数故障表现不佳。

为了进一步说明 CNN-BiLSTM 网络模型的优点, 在上文数据集的基础上, 设计了传统 CNN、BiLSTM、Transformer 网络结构, 每一种模型进行重复实验 20 次, 然后取平均值作为其准确率, 其结果如表 5 所示。

从表 5 可以看出, 使用单独的 CNN 或 BiLSTM 网络模型训练效果不如 CNN-BiLSTM, 这是因为

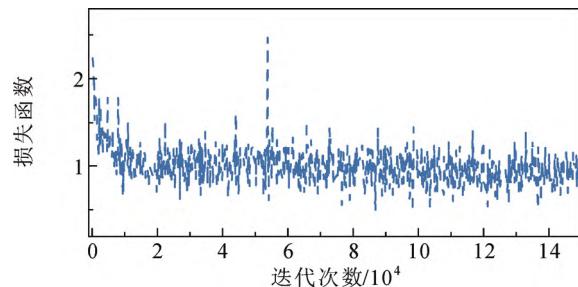


图 12 CNN-BiLSTM 的损失函数曲线

Fig.12 Loss function curve of CNN-BiLSTM

真实标签	0	1	2	3	4	5	6	7	8	预测标签
	34	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	0.0	13	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	0.0	0.0	17	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	0.0	0.0	0.0	25	0.0	0.0	0.0	0.0	0.0	0.0
	0.0	0.0	0.0	0.0	16	0.0	0.0	0.0	0.0	0.0
	0.0	0.0	0.0	0.0	0.0	23	0.0	0.0	0.0	0.0
	0.0	0.0	0.0	0.0	0.0	0.0	24	0.0	0.0	0.0
	0.0	0.0	0.0	0.0	0.0	0.0	0.0	32	0.0	0.0
	0.0	2.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	17

图 13 CNN-BiLSTM 在测试集上的混淆矩阵

Fig.13 CNN-BiLSTM confusion matrix on test set

CNN 虽然能够处理序列信息，但它不能挖掘序列时间维度的特征信息，所以结构较为简单的 CNN 平均准确率低；而 BiLSTM 能够挖掘时间序列的信息，但是单独的 BiLSTM 难以提取较长维度序列的特征信息；其次，Transformer 网络模型的平均准确率低于 30%，这是由于模型过大而训练样本太少，本文的数据集不足以训练 Transformer，导致其准确率低。最后，本文对使用 FFT 的数据集，使用所提出的 CNN-BiLSTM 进行故障分类，平均准确率仅得到了 88.66%，说明 CWT 结合本文所提出的故障诊断模型更具有优越性。

在实际工程应用中，同步电机运行的环境较为复杂，采集的 IFRA 数据可能伴随着不同程度的噪声，并且可能需将该网络模型对多台不同功率大小的同步电机进行故障诊断。所以，本文通过两组实验检验本文方法对不同程度噪声的鲁棒性及 CNN-BiLSTM 模型的泛化能力。第 1 组实验将 203 组测试集数据添加不同程度的白噪声，分别通过 CWT 和 FFT 进行时频转换，并利用上述所训练完成的模型对测试集进行测试，其结果如表 6 所示。第 2 组实验是以一台额定功率 8.5 kW、额定电压 380 V、2 极、36 槽散绕结构的同步电机开展定子绕组 IFRA 法测试，绕组故障位置、故障程度设置及脉冲信号参数均与上述同步电机设置一致，每一种故障取 3 组样本基于上述训练好的模型利用微调(fine-tune)技术做小样本学习(few-shot learning)，轮数为 10，其 IFRA 特征曲线见图 14。

可以从上述实验的结果得到：

1) 相比于不同的处理方法与模型，本文提出的基于 CWT 和 CNN-BiLSTM 诊断模型具有较高的故障诊断精度。

2) 输入为 CWT 数据处理后的模型准确率明显优于输入为 FFT 数据处理后的模型，例如 CNN-BiLSTM 模型精确度提升了 17.24%、19.71%、82.27%。相比于 FFT，CWT 对于处理带有噪声的暂态信号具有较强的适应性。

3) 相比于其他模型，以 SNR-30 为例，CNN-BiLSTM 的模型诊断精度分别提高了 48.24%、10.84%、76.35%，这表明 CNN-BiLSTM 模型能够有效地提取序列中的有效信息，从而提高 CNN-BiLSTM 模型的故障诊断精度。

4) 从图 14 可知，当发生匝间短路故障及接地故障时，IFRA 特征曲线第一共振点向高频区域移

表 5 不同模型及处理方法的性能统计表

Table 5 Performance statistics table for different models and processing methods

模型	数据处理方法	模型架构	平均准确率/%
传统网络模型	CWT	CNN	50.24
	CWT	BiLSTM	88.67
	CWT	Transformer	22.17
所提网络模型	CWT	CNN-BiLSTM	99.01
	FFT	CNN-BiLSTM	88.66

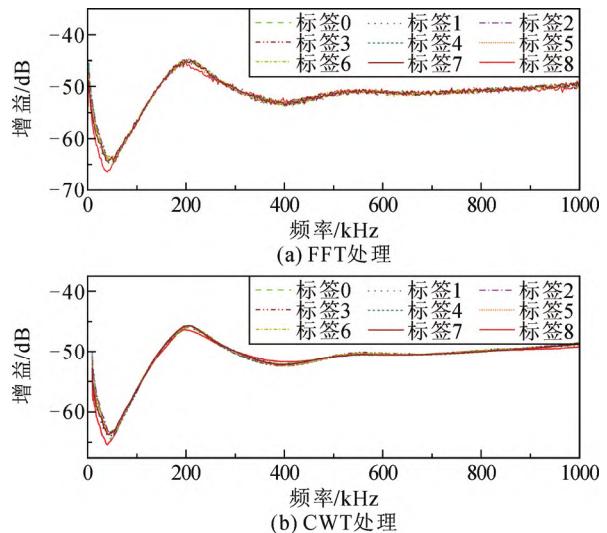


图 14 基于 FFT 和 CWT 变换的 8.5 kW 同步电机定子绕组 IFRA 曲线

Fig.14 Stator winding IFRA curve of 8.5 kW synchronous machine based on FFT and CWT transformations

表 6 不同模型及方法处理不同信噪比信号的性能统计

Table 6 Performance statistics of different models and methods for processing different SNR signals

处理方法	模型架构	准确率/%		
		SNR-30	SNR-20	SNR-10
CWT	CNN	50.24	47.78	44.33
	BiLSTM	87.68	86.20	83.74
	Transformer	22.17	22.17	20.95
	CNN-BiLSTM	98.52	98.52	97.04
FFT	CNN	43.84	34.48	7.88
	BiLSTM	71.42	68.97	12.31
	Transformer	20.68	20.20	9.85
	CNN-BiLSTM	81.28	78.81	14.77

动，且经过 CWT 变换后的频率响应曲线更为光滑，这与 5 kW 同步电机实验结果是一致的。此外，对 8.5 kW 电机进行小样本学习即通过对训练好的 CNN-BiLSTM 进行微调，在 10 轮内准确率达到 92.85%，说明训练好的模型对其他同类型的电机具有一定的参考价值。

5 结论

1) 对一台散绕结构的同步电机定子绕组宽频等效电路进行 SFRA 和 IFRA 的电路仿真, 结果表明两种方法具有等效性; 将加入白噪声的仿真数据分别进行 CWT 和 FFT 时频变换处理, 结果显示基于 CWT 处理的暂态信号的频率响应曲线更为平滑, 谐振点也基本接近于 SFRA, 表明 CWT 算法相对于 FFT 在实际工程运用中具有处理暂态信号的优越性; T-SNE 特征图可视化实验结果表明, 相比于 FFT, CWT 处理后的频域数据更有利于故障的辨识。

2) 提出了一种基于 CNN-BiLSTM 网络的绕组故障检测模型, 结果表明, 该模型的故障分类准确率达到 99.01%。其次, 与 LSTM、CNN、Transformer 相比, CNN-BiLSTM 的故障检测准确率明显优于其他方法。此外, 从噪声对比实验及泛化能力测试实验得知: 采用 CWT 处理后的数据经过不同网络模型诊断要优于 FFT, 且 CNN-BiLSTM 模型具有一定泛化能力。

3) 未来可通过微调网络权重使诊断模型适用于新电机的绕组故障诊断, 并使用更有效的元学习(meta learning)技术来进行优化改进。

参考文献 References

- [1] 陈庆国, 赵寒, 付强. 电老化对大型电机定子线棒主绝缘频域介电谱特性的影响[J]. 高电压技术, 2022, 48(11): 4255-4263.
CHEN Qingguo, ZHAO Han, FU Qiang. Effect of electric aging on frequency domain dielectric properties of main insulation of generator stator[J]. High Voltage Engineering, 2022, 48(11): 4255-4263.
- [2] 付强, 梁良, 王占一, 等. 大型发电机主绝缘的高导热胶黏剂导热及介电性能[J]. 高电压技术, 2021, 47(2): 652-662.
FU Qiang, LIANG Liang, WANG Zhanyi, et al. Thermal conductivity and dielectric properties of high thermal conductivity adhesive in main insulation for large generators[J]. High Voltage Engineering, 2021, 47(2): 652-662.
- [3] 唐艳霞, 刘学忠, 王景娜, 等. 重复脉冲电压下变频牵引电机绕组绝缘的电树枝特性[J]. 高电压技术, 2023, 49(6): 2625-2633.
TANG Yanxia, LIU Xuezong, WANG Jingna, et al. Electrical tree characteristics in winding insulation for inverter-fed traction motor under repetitive impulse voltages[J]. High Voltage Engineering, 2023, 49(6): 2625-2633.
- [4] 张建文, 姚奇, 朱宁辉, 等. 异步电动机定子绕组的故障诊断方法[J]. 高电压技术, 2007, 33(6): 114-117.
ZHANG Jianwen, YAO Qi, ZHU Ninghui, et al. Method for diagnosing the stator winding faults in squirrel cage induction motor[J]. High Voltage Engineering, 2007, 33(6): 114-117.
- [5] 杜威, 孙宇光, 田代宗, 等. 基于新型探测线圈的永磁电机转子失磁故障在线监测方法[J]. 电力自动化设备, 2020, 40(6): 218-224.
DU Wei, SUN Yuguang, TIAN Daizong, et al. Online monitoring method for rotor demagnetization fault of permanent magnet synchronous machine based on new type of search coil[J]. Electric Power Automation Equipment, 2020, 40(6): 218-224.
- [6] 张超, 夏立, 吴正国, 等. 同步发电机转子绕组匝间短路故障特征规律分析[J]. 高电压技术, 2010, 36(6): 1506-1512.
ZHANG Chao, XIA Li, WU Zhenguo, et al. Analysis on fault characteristics law of interturn short circuit in synchronous generator rotor winding[J]. High Voltage Engineering, 2010, 36(6): 1506-1512.
- [7] 赵仲勇, 唐超, 李成祥, 等. 基于频率响应二值化图像的变压器绕组变形故障诊断方法[J]. 高电压技术, 2019, 45(5): 1526-1534.
ZHAO Zhongyong, TANG Chao, LI Chengxiang, et al. Diagnosis method of transformer winding deformation faults based on frequency response binary image[J]. High Voltage Engineering, 2019, 45(5): 1526-1534.
- [8] 赵仲勇, 姚陈果, 李成祥, 等. 基于短时 Fourier 变换的变压器绕组变形脉冲频率响应曲线获取方法[J]. 高电压技术, 2016, 42(1): 241-247.
ZHAO Zhongyong, YAO Chenguo, LI Chengxiang, et al. Method for obtaining the impulse frequency response curves of power transformer winding deformation based on short time Fourier transform[J]. High Voltage Engineering, 2016, 42(1): 241-247.
- [9] MAYORA H, ALVAREZ R, BOSSIO G, et al. Condition assessment of rotating electrical machines using SFRA – A survey[C]//Proceedings of 2021 IEEE Electrical Insulation Conference. Denver, CO, USA: IEEE, 2021: 26-29.
- [10] FLORKOWSKI M, FURGAŁ J. Modelling of winding failures identification using the frequency response analysis (FRA) method[J]. Electric Power Systems Research, 2009, 79(7): 1069-1075.
- [11] LAMARRE L, PICHÉ P. Impedance characterization of hydro generator stator windings and preliminary results of FRA analysis[C]//Proceedings of Conference Record of the 2008 IEEE International Symposium on Electrical Insulation. Vancouver, BC, Canada: IEEE, 2008: 227-230.
- [12] BLÁNQUEZ F R, PLATERO C A, REBOLLO E, et al. Evaluation of the applicability of FRA for inter-turn fault detection in stator windings[C]//Proceedings of the 2013 9th IEEE International Symposium on Diagnostics for Electric Machines. Valencia, Spain: IEEE, 2013: 177-182.
- [13] SMALL B J, ABU-SIADA A. A new method for analysing transformer condition using frequency response analysis[C]//Proceedings of 2011 IEEE Power and Energy Society General Meeting. Detroit, MI, USA: IEEE, 2011: 1-5.
- [14] 李宁, 左培丽, 王新刚, 等. 基于改进 DFT 和时域准同步的间谐波检测算法[J]. 电力自动化设备, 2017, 37(4): 170-178.
LI Ning, ZUO Peili, WANG Xingang, et al. Inter-harmonic detection based on improved DFT and time-domain quasi-synchronization[J]. Electric Power Automation Equipment, 2017, 37(4): 170-178.
- [15] CHEN Y, ZHAO Z Y, YU Y Q, et al. Understanding IFRA for detecting synchronous machine winding short circuit faults based on image classification and smooth grad-CAM++[J]. IEEE Sensors Journal, 2023, 23(3): 2422-2432.
- [16] RAWAT W, WANG Z H. Deep convolutional neural networks for image classification: a comprehensive review[J]. Neural Computation, 2017, 29(9): 2352-2449.
- [17] 马航宇, 周笛, 潘尔顺. 基于深度置信网络的旋转部件半监督故障诊断[J]. 机械设计, 2021, 38(12): 1-6.
MA Hangyu, ZHOU Di, PAN Ershun. Semi-supervised fault diagnosis on rotating parts based on the deep belief network[J]. Journal of Machine Design, 2021, 38(12): 1-6.
- [18] 王波, 刘树林, 张宏利, 等. 相关向量机及其在机械故障诊断中的应用研究进展[J]. 振动与冲击, 2015, 34(5): 145-153, 167.

- WANG Bo, LIU Shulin, ZHANG Hongli, et al. Advances about relevance vector machine and its applications in machine fault diagnosis[J]. Journal of Vibration and Shock, 2015, 34(5): 145-153, 167.
- [19] 兰孝升, 李云凤, 苏元浩, 等. 基于关联度与自检验长短期记忆网络的风电机组轴承寿命预测模型[J]. 高电压技术, 2023, 49(6): 2652-2661.
- LAN Xiaosheng, LI Yunfeng, SU Yuanhao, et al. Wind turbine bearing life prediction model based on indexed relation and self-checking long short-term memory[J]. High Voltage Engineering, 2023, 49(6): 2652-2661.
- [20] 李俊卿, 李斯璇, 陈雅婷, 等. 一种基于 CGAN-CNN 的同步电机转子绕组匝间短路故障诊断方法[J]. 电力自动化设备, 2021, 41(8): 169-174.
- LI Junqing, LI Sixuan, CHEN Yating, et al. Fault diagnosis method of inter-turn short circuit of rotor winding of synchronous motor based on CGAN-CNN[J]. Electric Power Automation Equipment, 2021, 41(8): 169-174.
- [21] 李俊卿, 陈雅婷, 李斯璇. 基于深度置信网络的同步发电机励磁绕组匝间短路故障预警[J]. 电力自动化设备, 2021, 41(2): 153-158.
- LI Junqing, CHEN Yating, LI Sixuan. Early warning of inter-turn short circuit fault in excitation windings of synchronous generator based on deep belief network[J]. Electric Power Automation Equipment, 2021, 41(2): 153-158.
- [22] CHEN Y, ZHAO Z Y, WU H Z, et al. Fault anomaly detection of synchronous machine winding based on isolation forest and impulse frequency response analysis[J]. Measurement, 2022, 188: 110531.
- [23] WAN S T, HE P. Rotor winding inter-turn short circuit fault diagnosis system based on artificial neural network[C]// Proceedings of the 2007 8th International Conference on Electronic Measurement and Instruments. Xi'an, China: IEEE, 2007: 3-581-3-585.
- [24] 王攀攀, 史丽萍, 苗长新, 等. 利用骨干微粒群算法和 SVM 诊断电机定子故障[J]. 电机与控制学报, 2013, 17(2): 48-54.
- WANG Panpan, SHI Liping, MIAO Changxin, et al. Diagnosing stator fault in motors by using bare-bones particle swarm optimization algorithm and SVM[J]. Electric Machines and Control, 2013, 17(2): 48-54.
- [25] MUGARRA A, MAYORA H, GUERRERO J M, et al. Frequency response analysis (FRA) fault diagram assessment method[J]. IEEE Transactions on Industry Applications, 2022, 58(1): 336-344.
- [26] BLÁZQUEZ F R, PLATERO C A, REBOLLO E, et al. Field-winding fault detection in synchronous machines with static excitation through frequency response analysis[J]. International Journal of Electrical Power & Energy Systems, 2015, 73: 229-239.
- [27] MUGARRA A, PLATERO C A, MARTÍNEZ J A, et al. Validity of frequency response analysis (FRA) for diagnosing large salient poles of synchronous machines[J]. IEEE Transactions on Industry Applications, 2020, 56(1): 226-234.
- [28] PLATERO C A, BLÁZQUEZ F, FRÍAS P, et al. Influence of rotor position in FRA response for detection of insulation failures in salient-pole synchronous machines[J]. IEEE Transactions on Energy Conversion, 2011, 26(2): 671-676.
- [29] 赵仲勇. 基于脉冲耦合注入的变压器绕组变形故障检测方法研究[D]. 重庆: 重庆大学, 2017.
- ZHAO Zhongyong. Study on method of detecting power transformer winding deformation fault based on pulse coupling injection[D]. Chongqing, China: Chongqing University, 2017.
- [30] ZHAO Z Y, TANG C, YAO C G, et al. Improved method to obtain the online impulse frequency response signature of a power transformer by multi scale complex CWT[J]. IEEE Access, 2018, 6: 48934-48945.
- [31] ZHAO Z Y, CHEN Y, YU Y Q, et al. Equivalent broadband electrical circuit of synchronous machine winding for frequency response analysis based on gray box model[J]. IEEE Transactions on Energy Conversion, 2021, 36(4): 3512-3521.



YU Yueqiang

于跃强
1994—, 男, 硕士
主要从事电气设备状态检测与故障智能诊断研究
E-mail: yuyueqiang@swu.edu.cn



ZHAO Zhongyong
Ph.D.
Associate professor
Corresponding author

赵仲勇(通信作者)
1988—, 男, 博士, 副教授
主要从事电气设备故障智能检测和脉冲功率技术及其应用
E-mail: zhaozy1988@swu.edu.cn